Uema
UNIVERSIDADE ESTADUAL
DO MARANHÃO

Aula 12

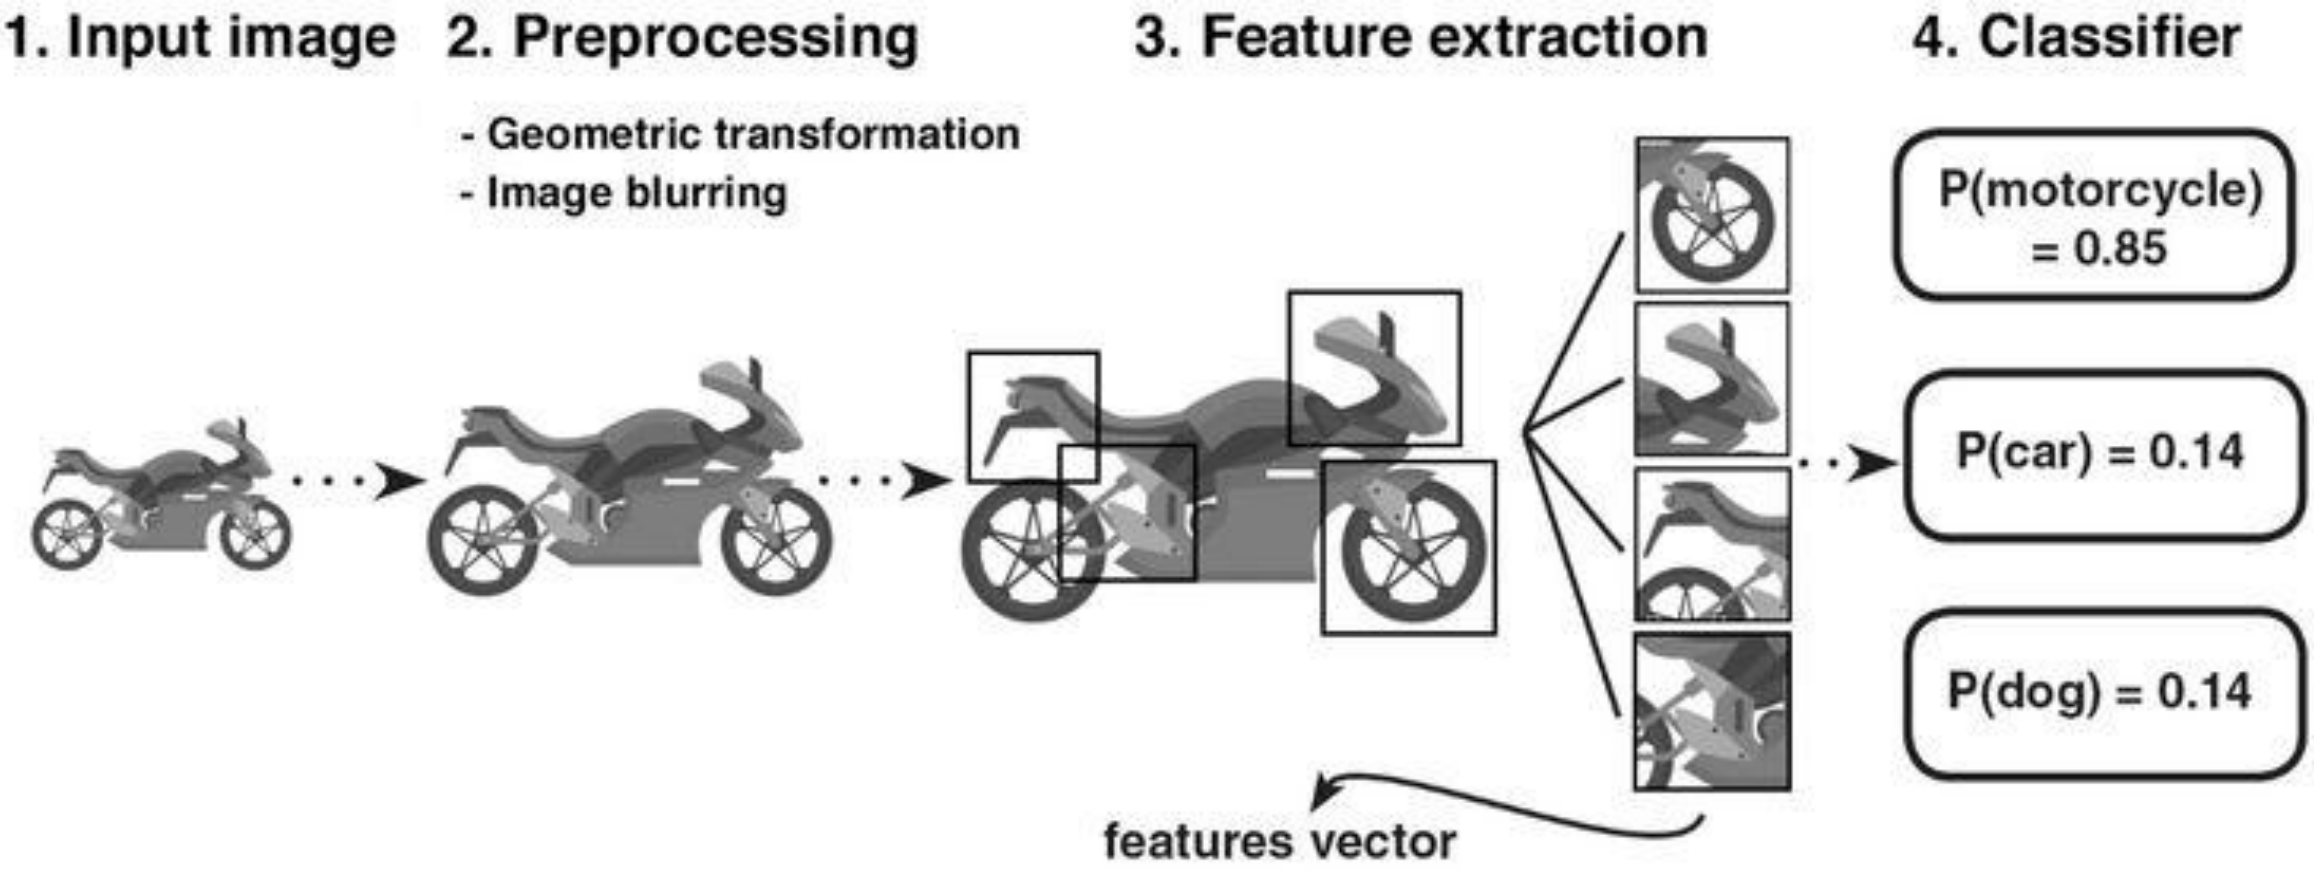
Machine Vision - Introdução

Prof. Dr. Lúcio Flávio de A Campos

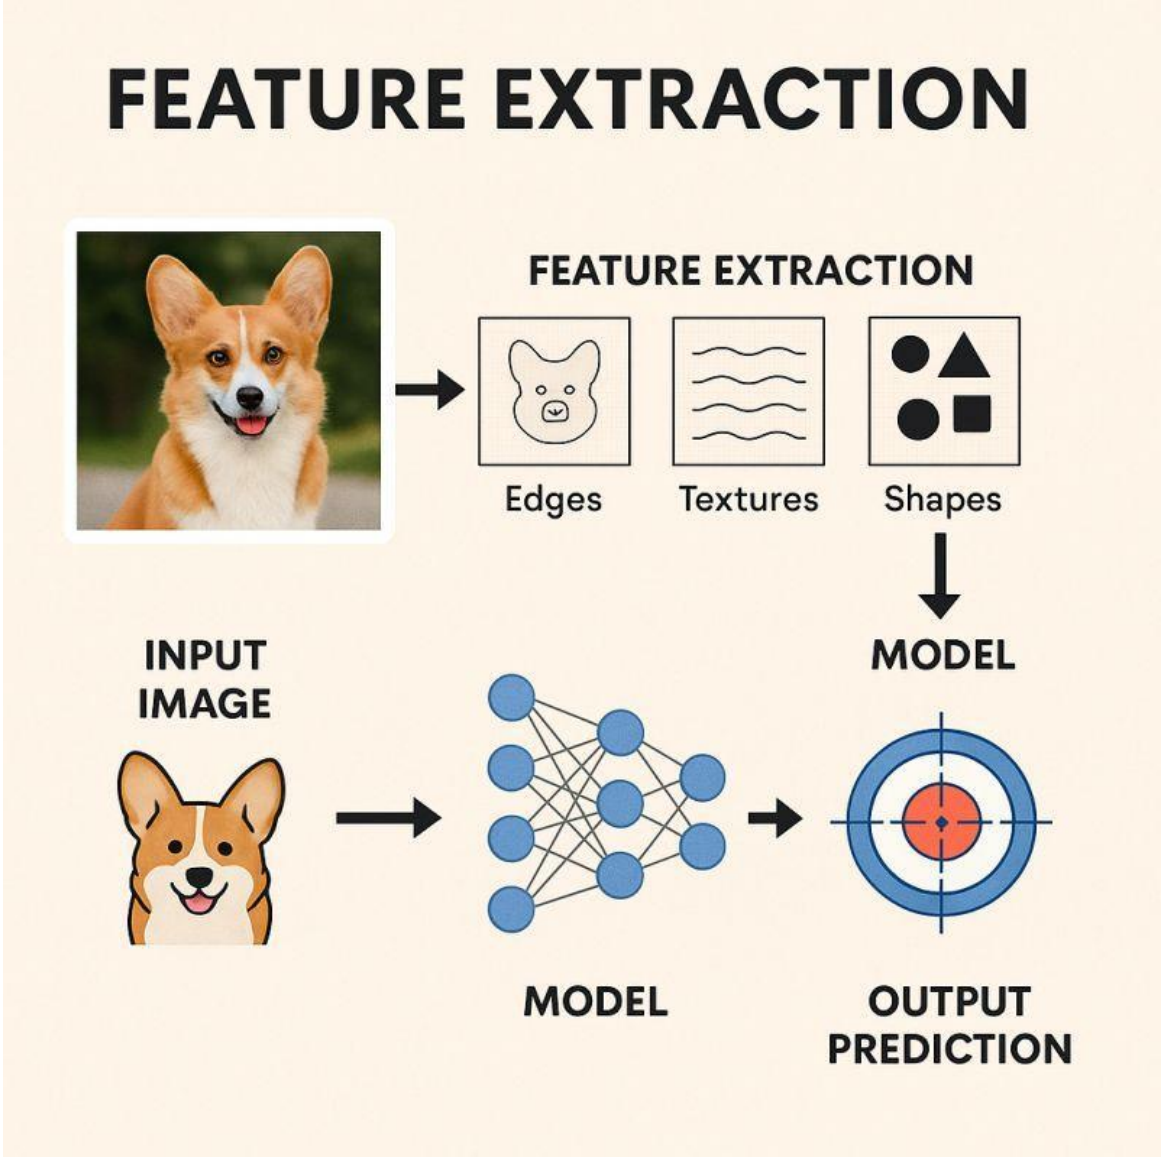


LabVIR
Laboratório de Visão Computacional,
Inteligência e Robótica - Uema

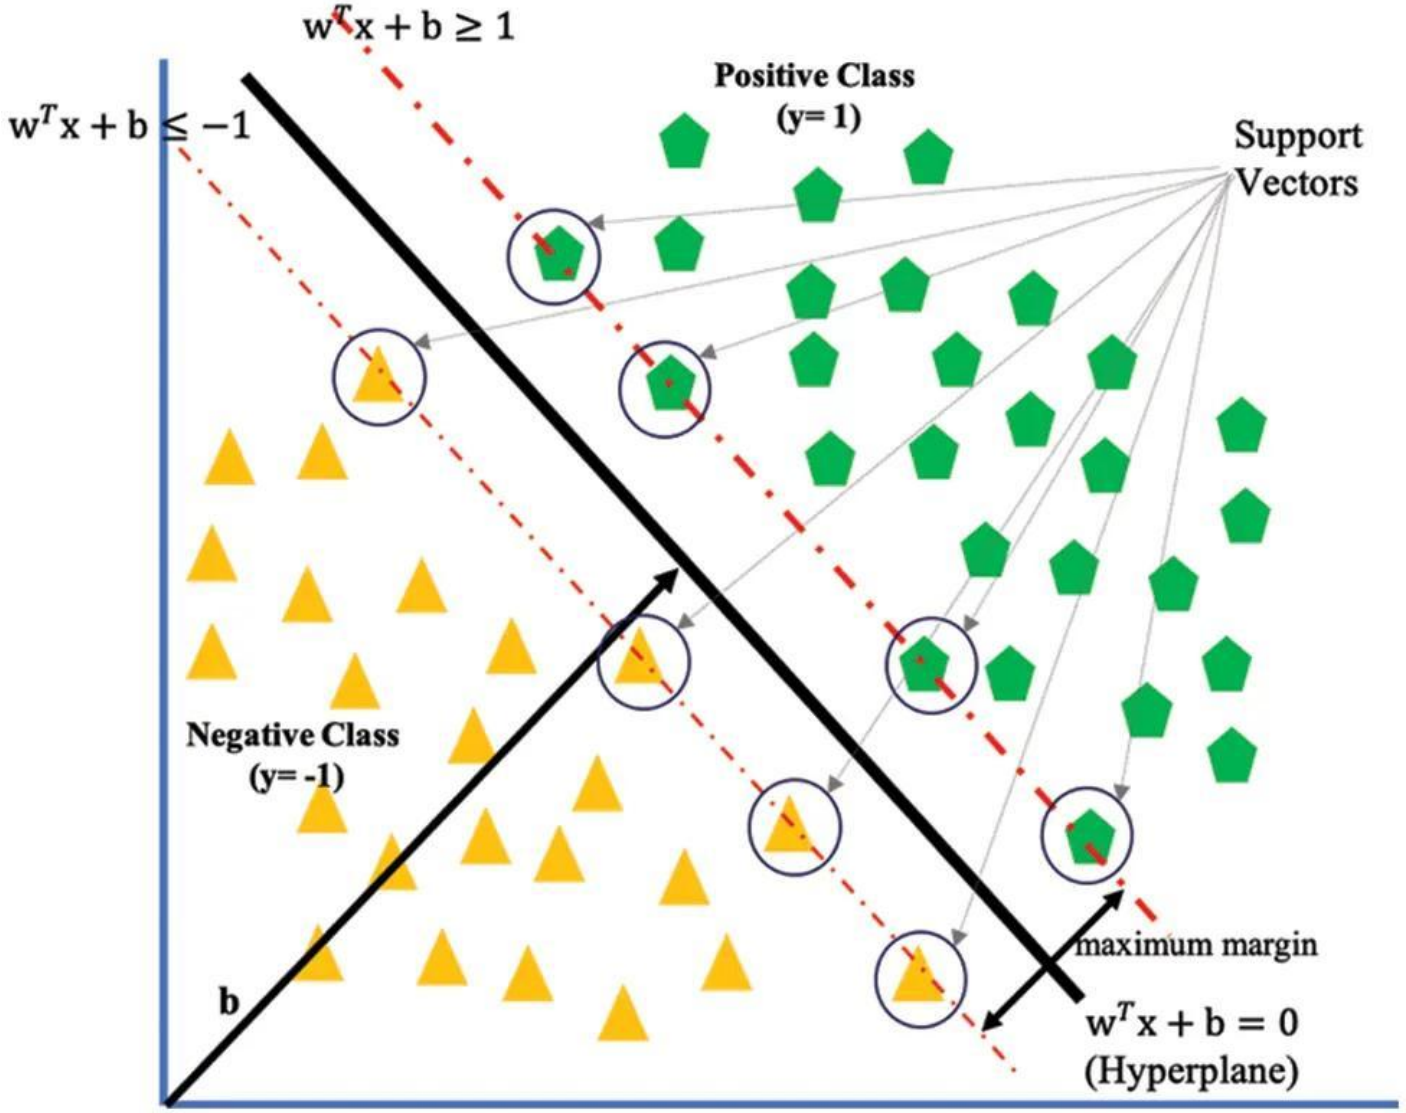
Como uma máquina aprende a reconhecer imagens



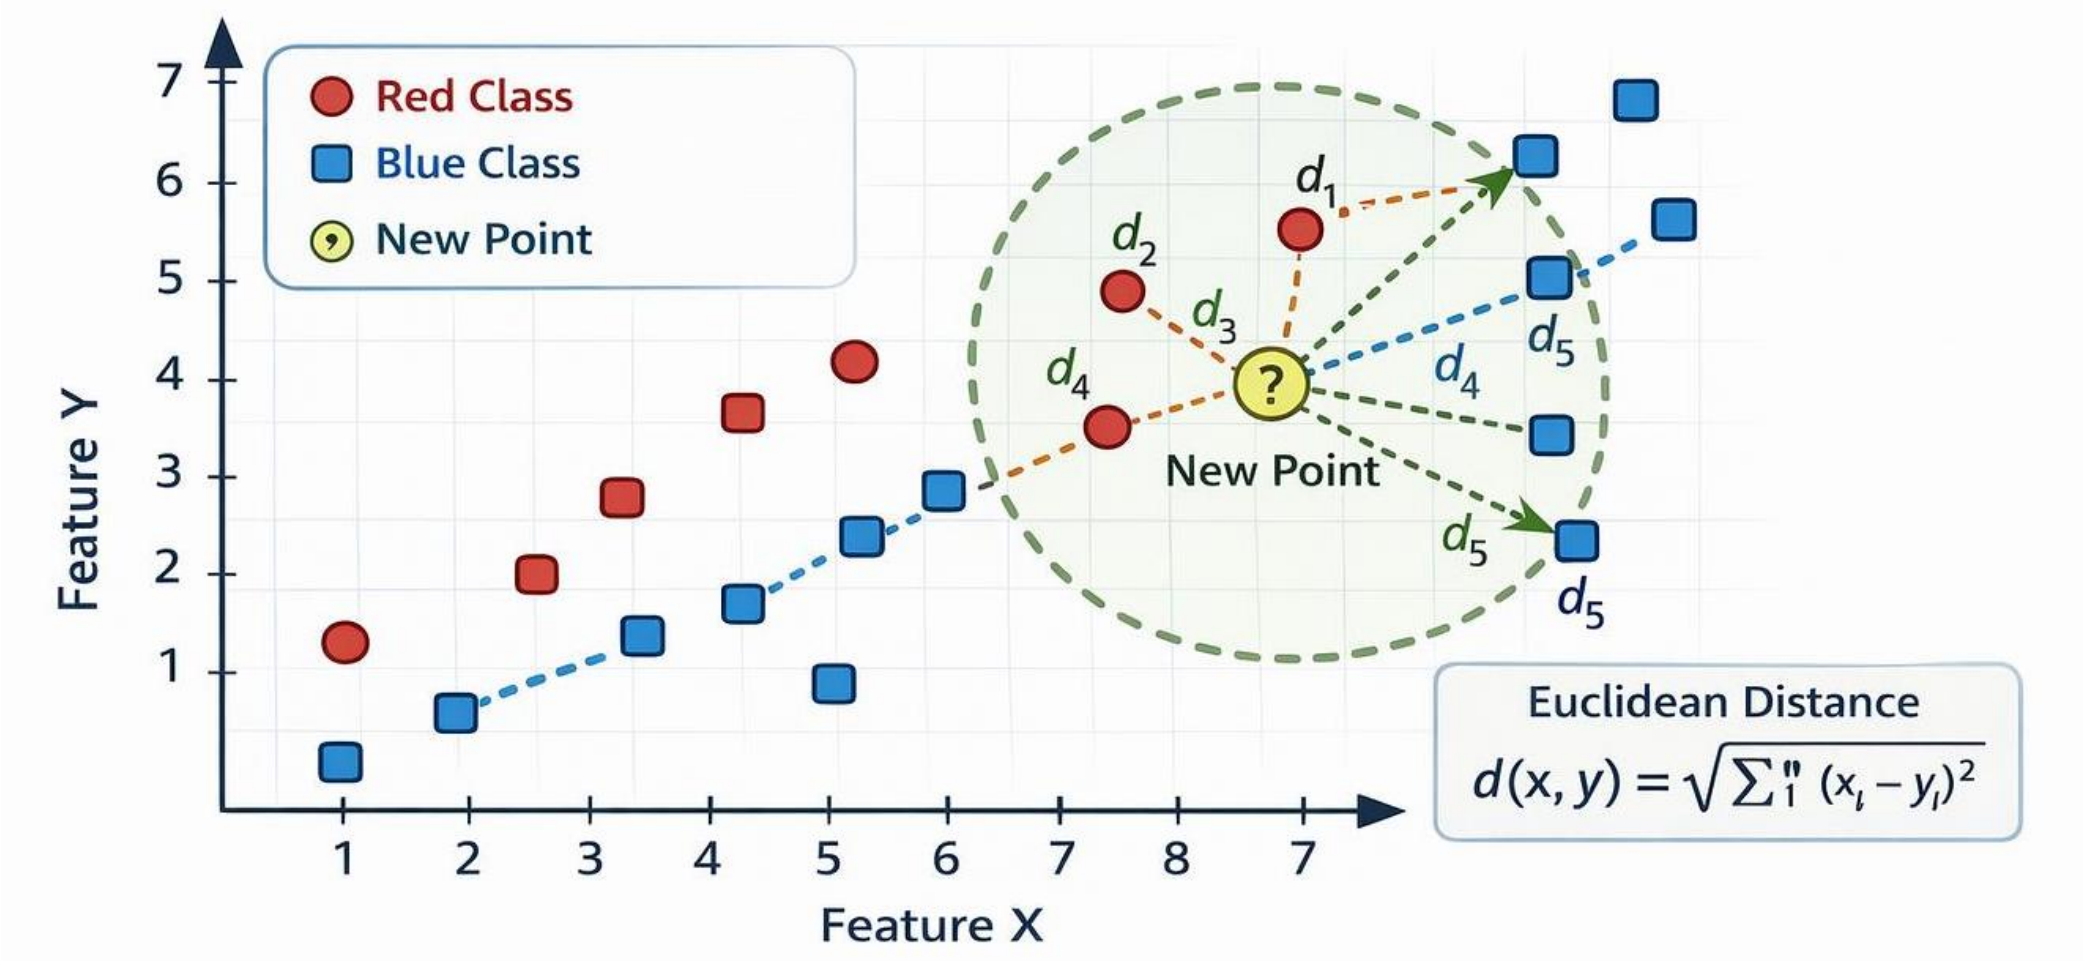
Como uma máquina aprende a reconhecer imagens



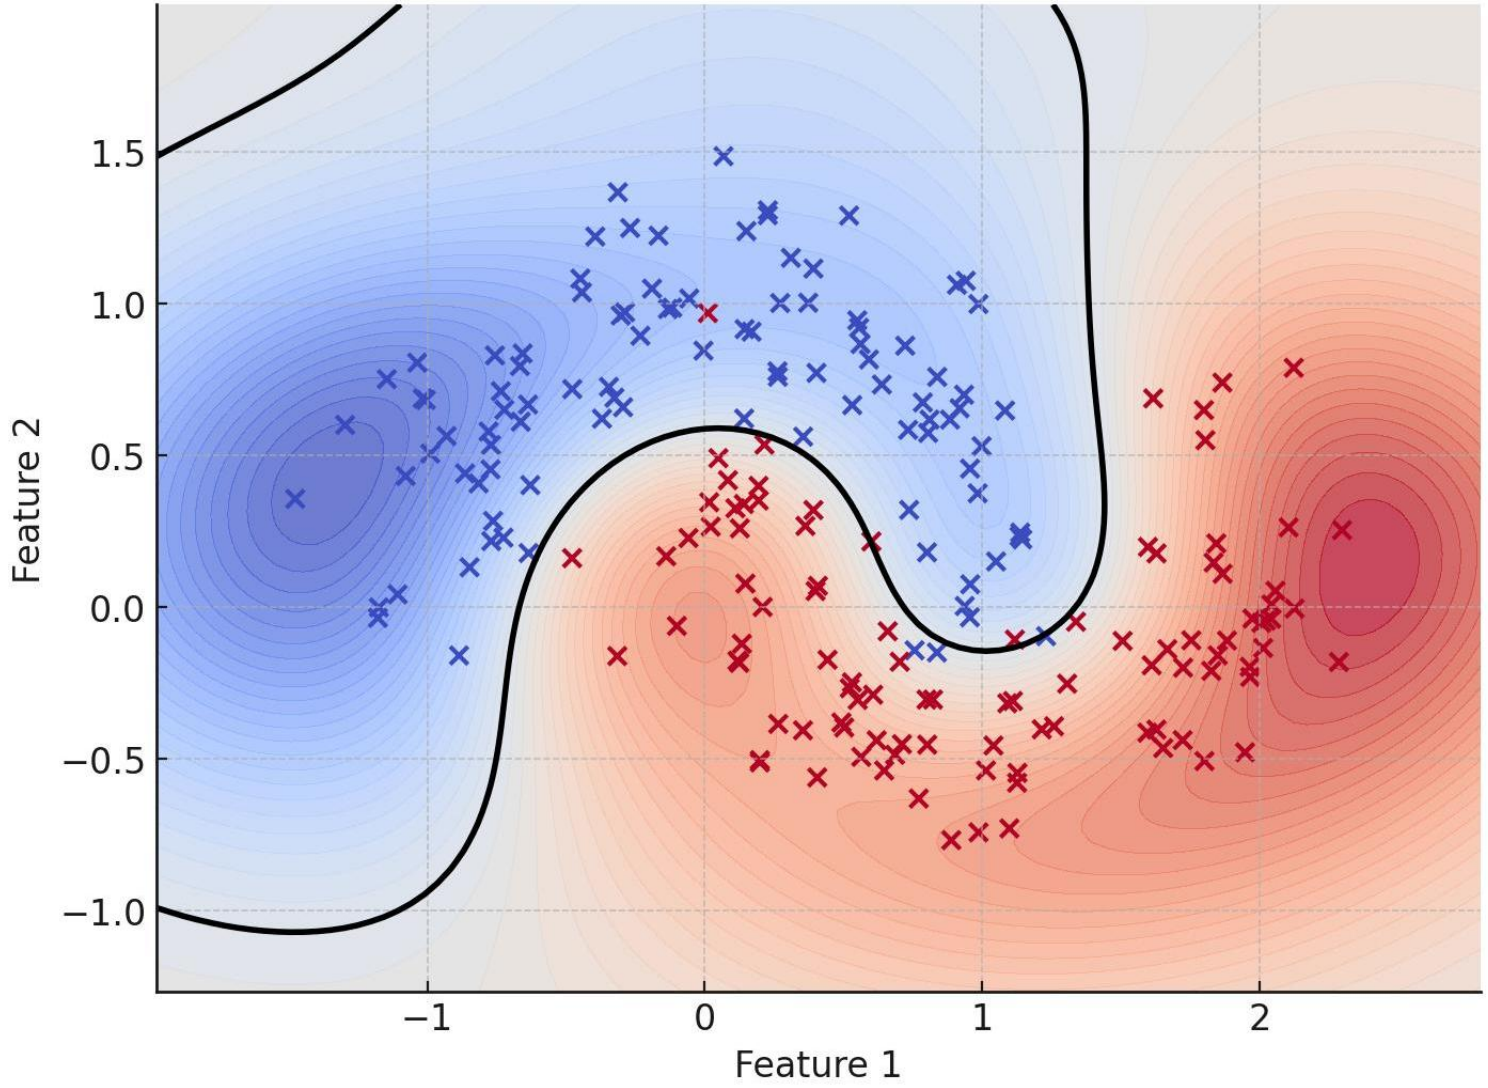
Como uma máquina aprende a reconhecer imagens



Como uma máquina aprende a reconhecer imagens



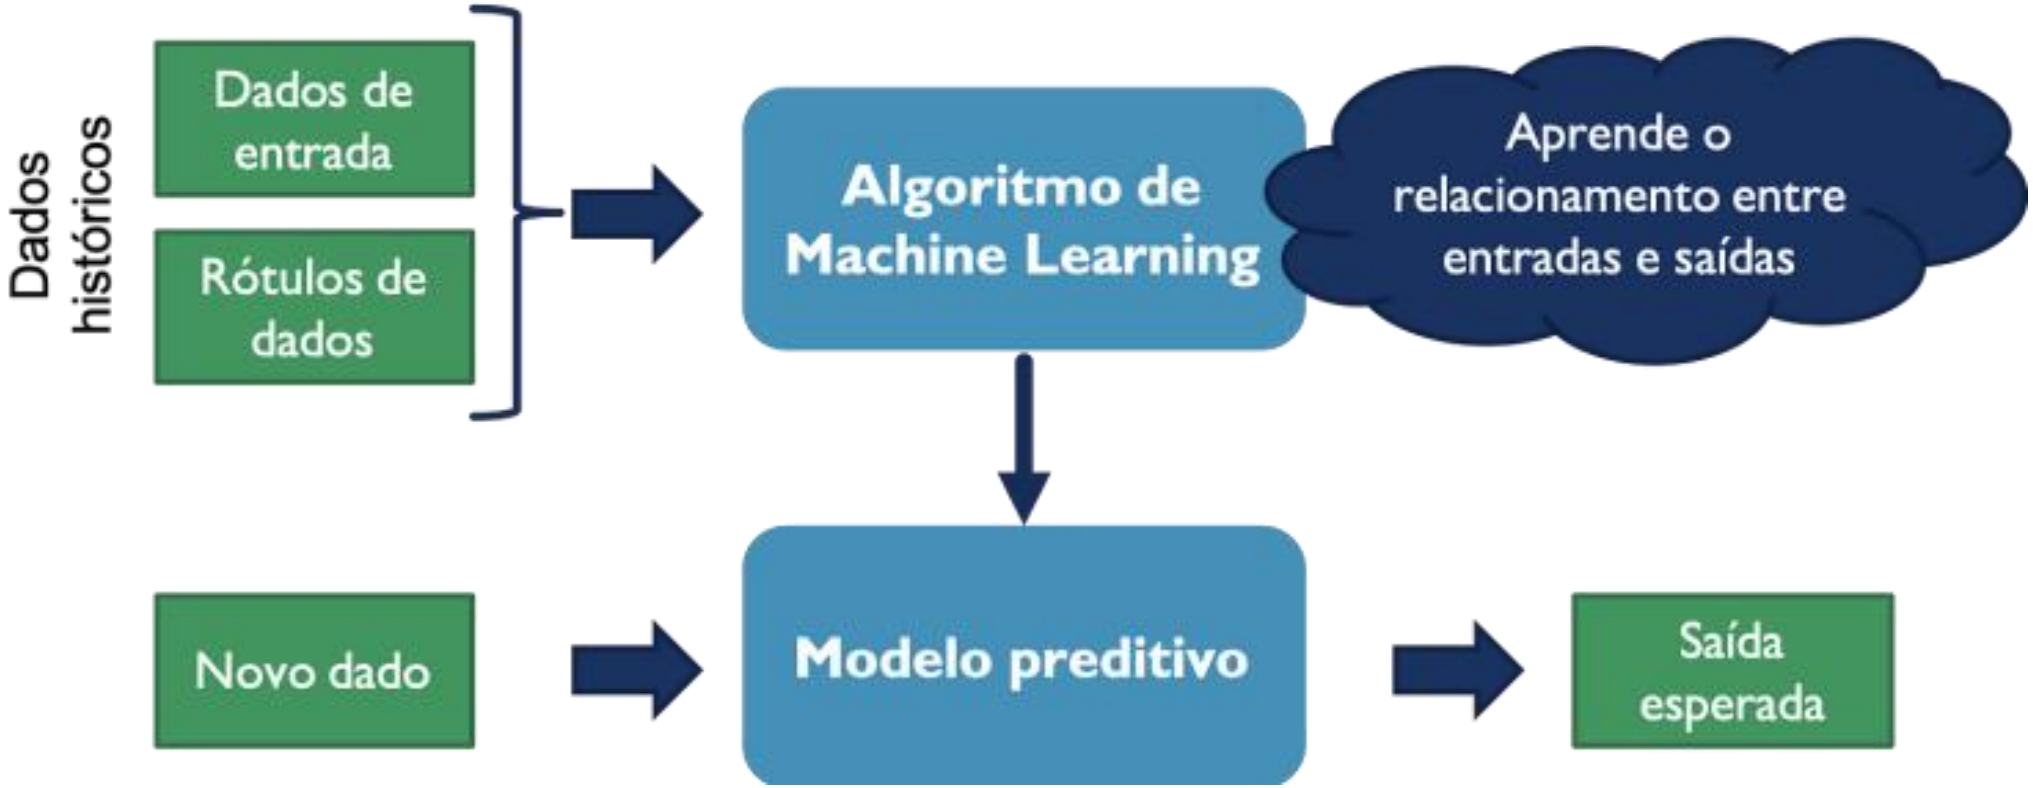
Como uma máquina aprende a reconhecer imagens



Aprendizado em Machine Vision

- Aprendizado Supervisionado: O modelo aprende a partir de dados que já possuem respostas corretas.
  - Como ensinar um algoritmo a reconhecer fotos de gatos e cachorros, mostrando varias fotos (identificadas) de ambos animais, induzindo o aprendizado

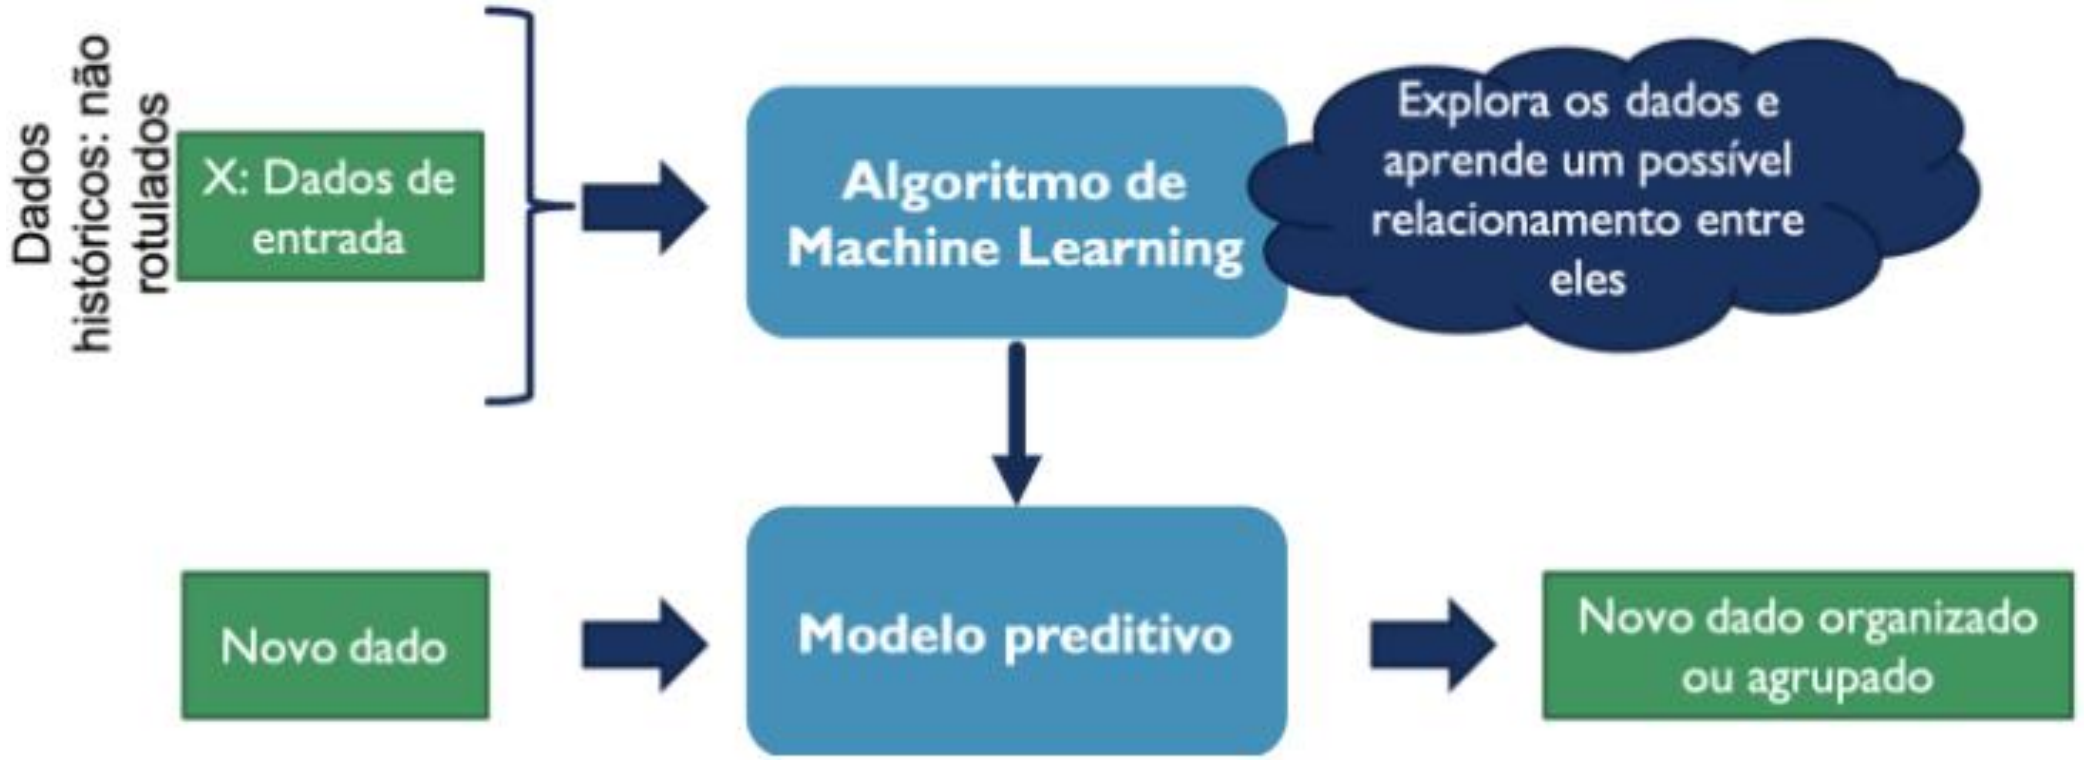
Aprendizado em Machine Vision



Aprendizado em Machine Vision

- Aprendizado Não - Supervisionado: O algoritmo encontra **padrões** sozinho, em dados que não possuem rótulo.
  - IA que cria perfil de clientes, em um pequeno questionário.

Aprendizado em Machine Vision



Aprendizado em Machine Vision

Tipo de Aprendizado	Algoritmos de Exemplo
Aprendizado Supervisionado	Regressão Linear, Árvores de Decisão, Redes Neurais Artificiais, Support Vector Machines (SVM), Naive Bayes, K-Nearest Neighbors (KNN), Random Forest, Gradient Boosting, entre outros.
Aprendizado Não-Supervisionado	K-Means Clustering, Análise de Componentes Principais (PCA), Algoritmo de Associação Apriori, Hierarchical Clustering, Gaussian Mixture Models (GMM), entre outros.

O que aprendemos até aqui

- Filtragem e suavização;
- Detecção de bordas;
- Conversão de espaços de cores;
- Operações morfológicas;
- Segmentação por limiarização;
- Extração de contornos;
- Subtração de backgrounds.

Técnicas que aprenderemos em Machine Vision

- KNN (K Nearest Neighbours)
- SVM (Suport Vector Machine)
- MLP (MultiLayer Perceptron) Neural Networks
- CNN (Convolution Neural Networks) e suas evoluções

Técnicas que aprenderemos em Machine Vision

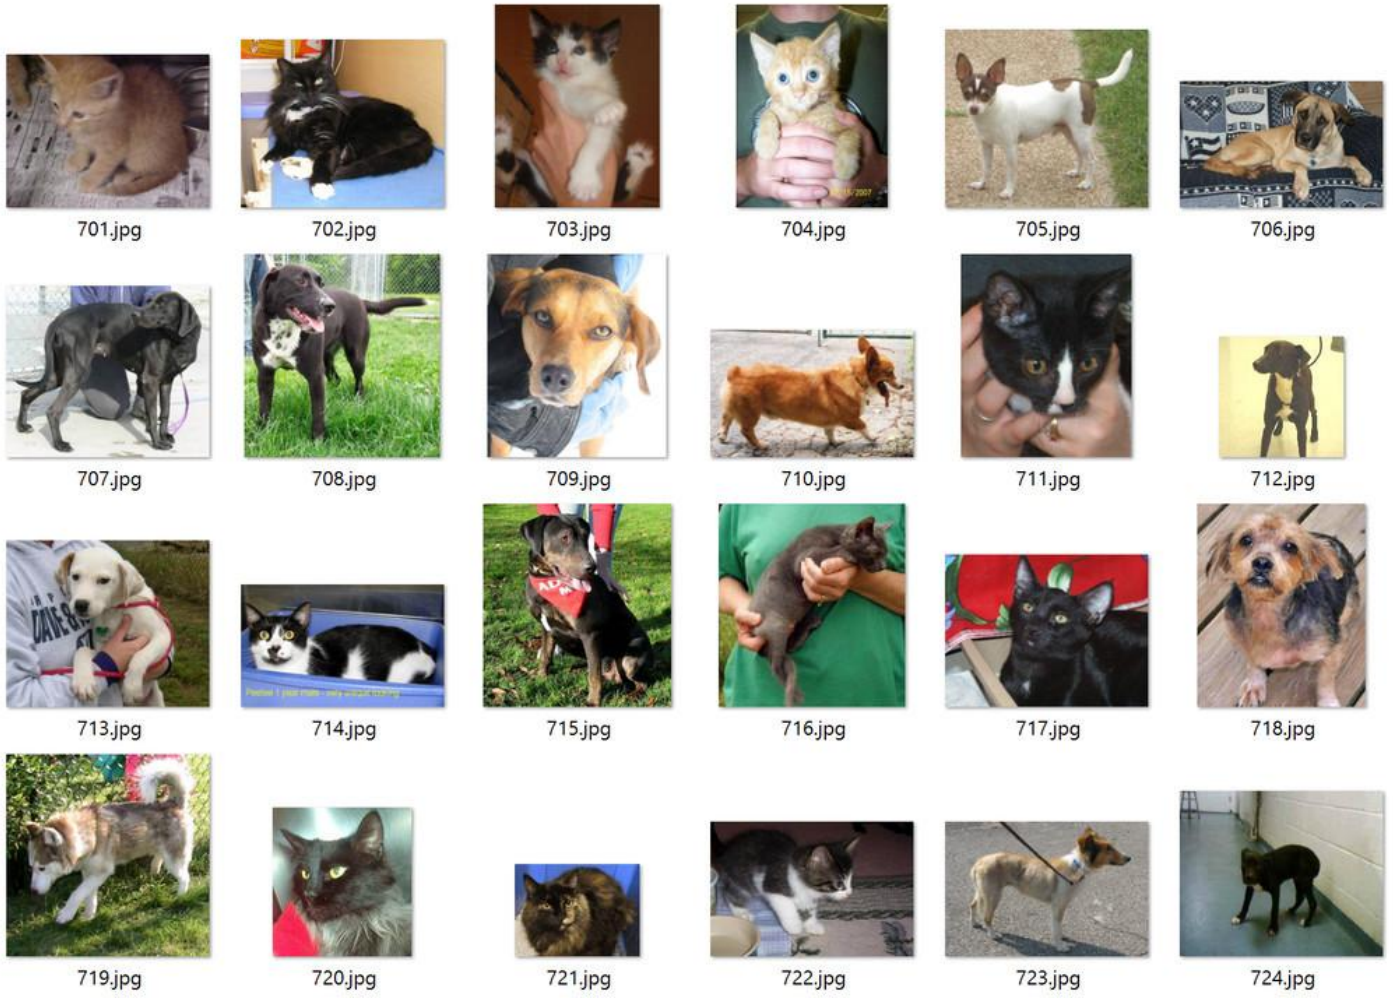
- KNN (K Nearest Neighbours)
- SVM (Suport Vector Machine)
- MLP (MultiLayer Perceptron) Neural Networks
- CNN (Convolution Neural Networks) e suas evoluções

Entendendo Conceitos Principais

- Dataset
- Amostras e características (features);
- Rótulos (labels);
- Treinamento e inferência;
- Aprendizado supervisionado;
- Treino, validação e teste;
- Generalização e overfitting

Entendendo Conceitos Principais

- **Dataset**: Conjunto de dados utilizado para desenvolver e avaliar um modelo de aprendizado de máquina



Entendendo Conceitos Principais

- **Amostras e características (features)**: cada amostra é um elemento individual do dataset, como uma imagem de um animal.
  - As características são as informações extraídas dessas amostras e utilizadas pelo algoritmo para identificar padrões.



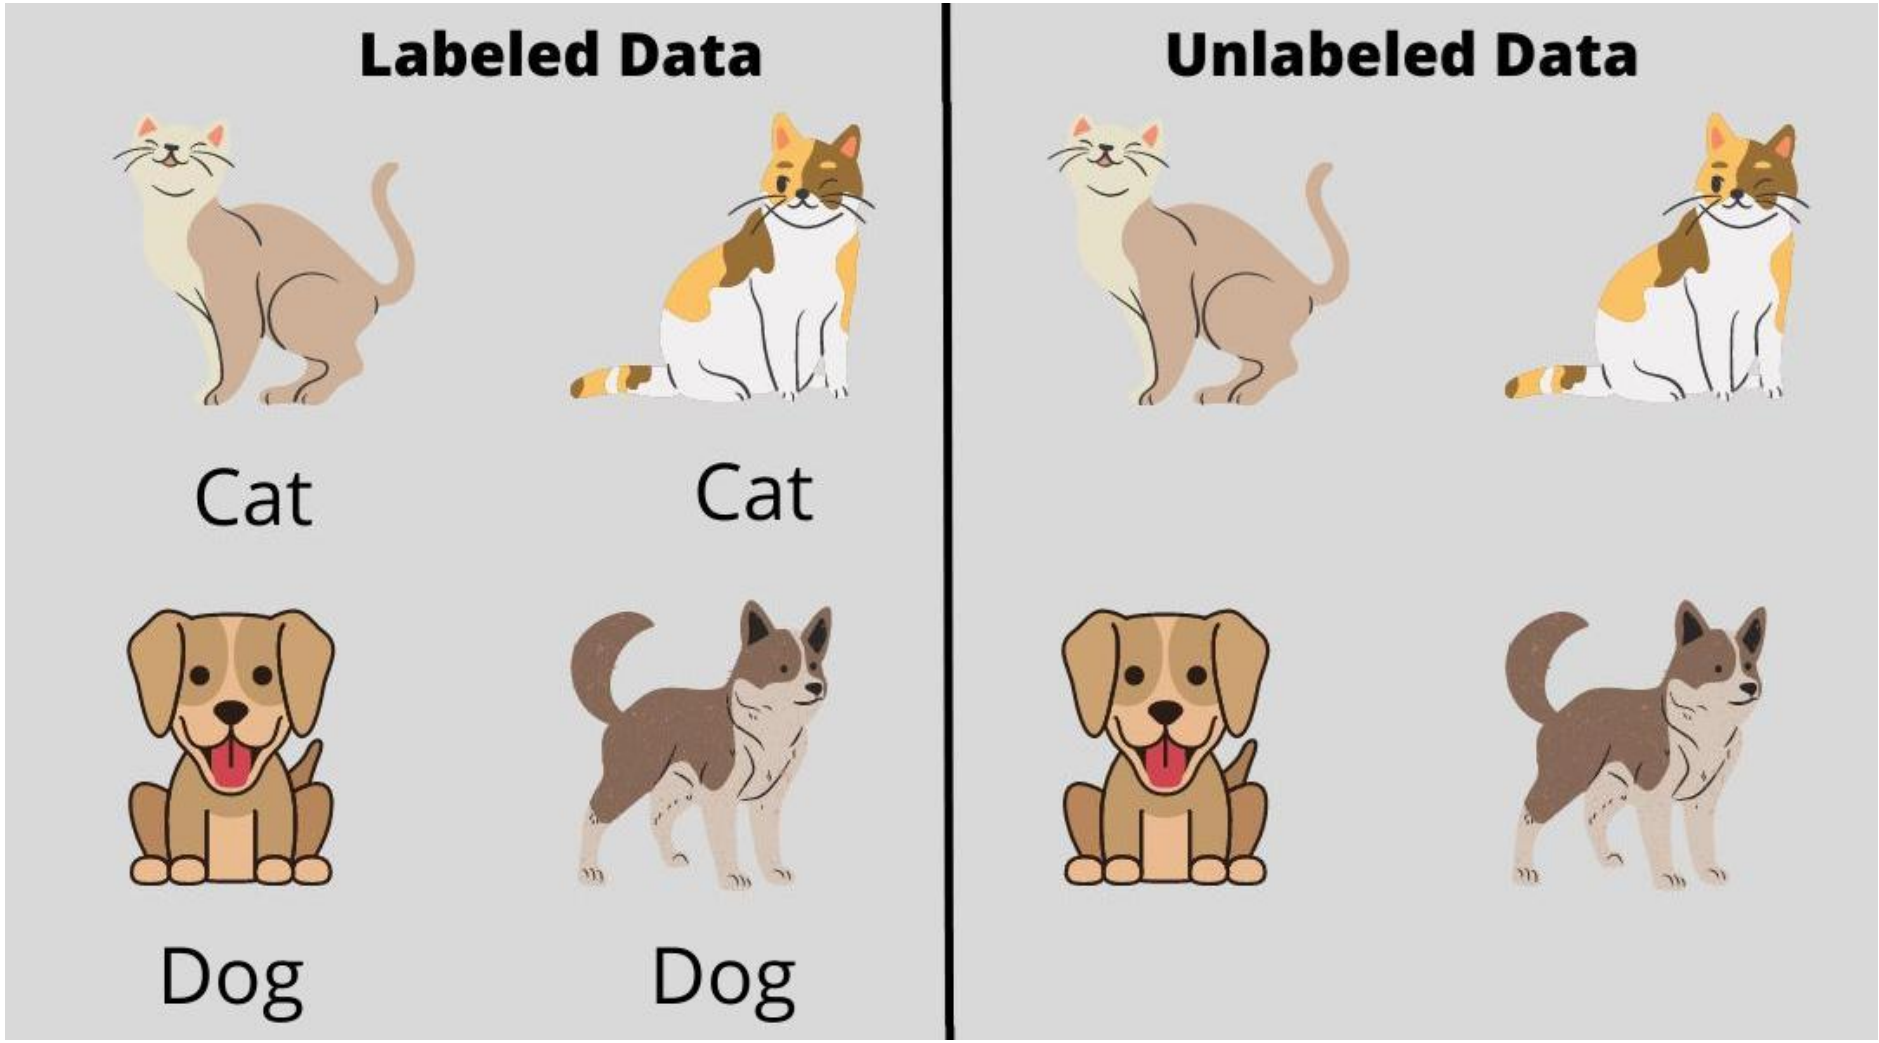
→

Vetor de características

$$[0.85,\ 0.12,\ 0.63,\ 0.91]$$

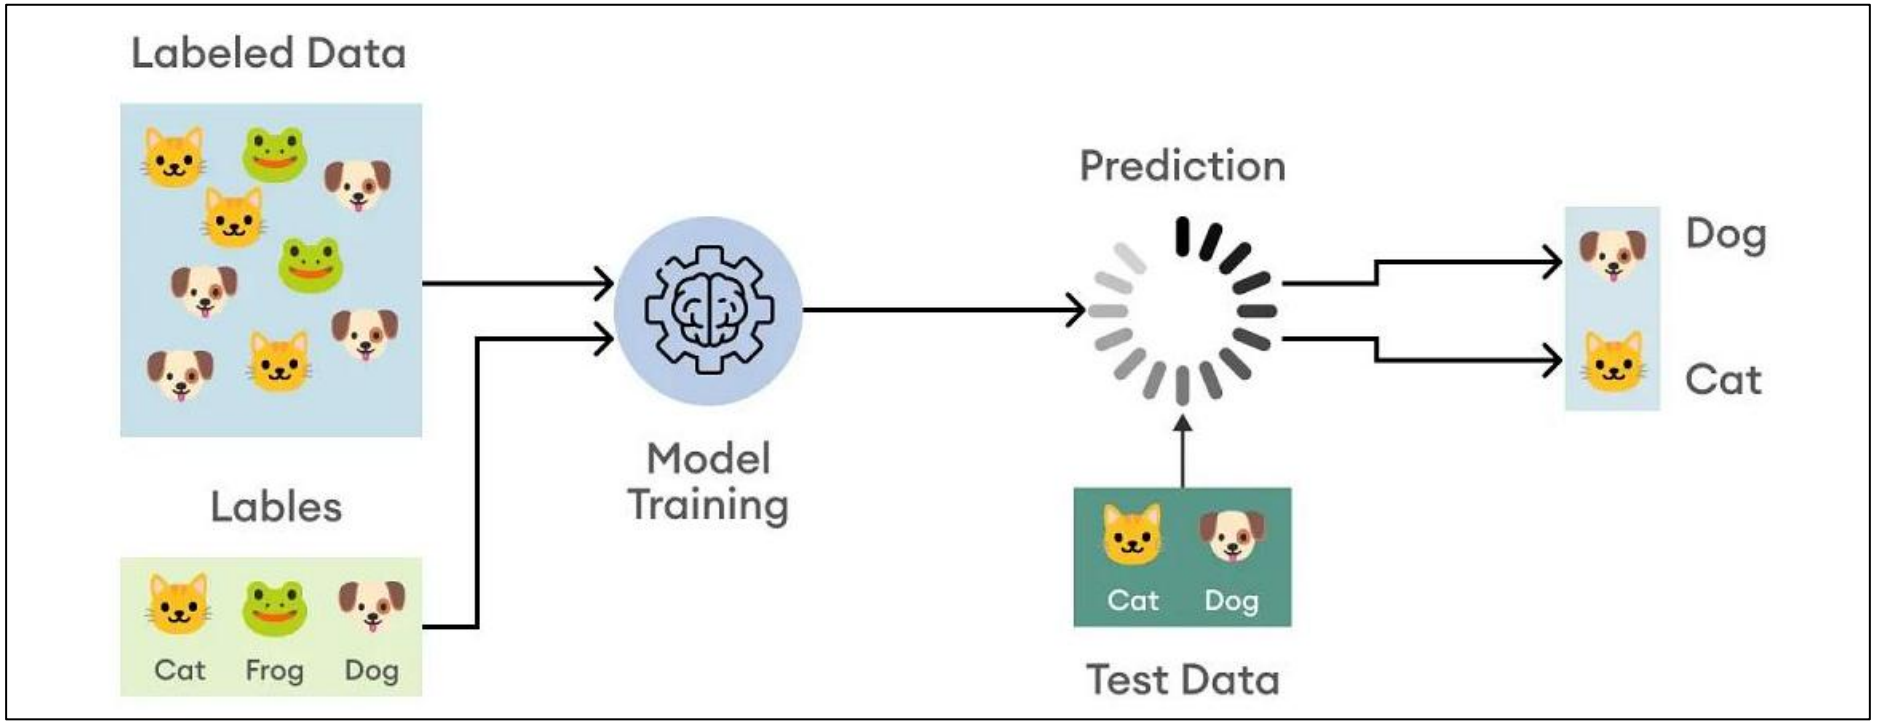
Entendendo Conceitos Principais

- **Rótulos (labels)**: são as categorias ou respostas associadas às amostras.



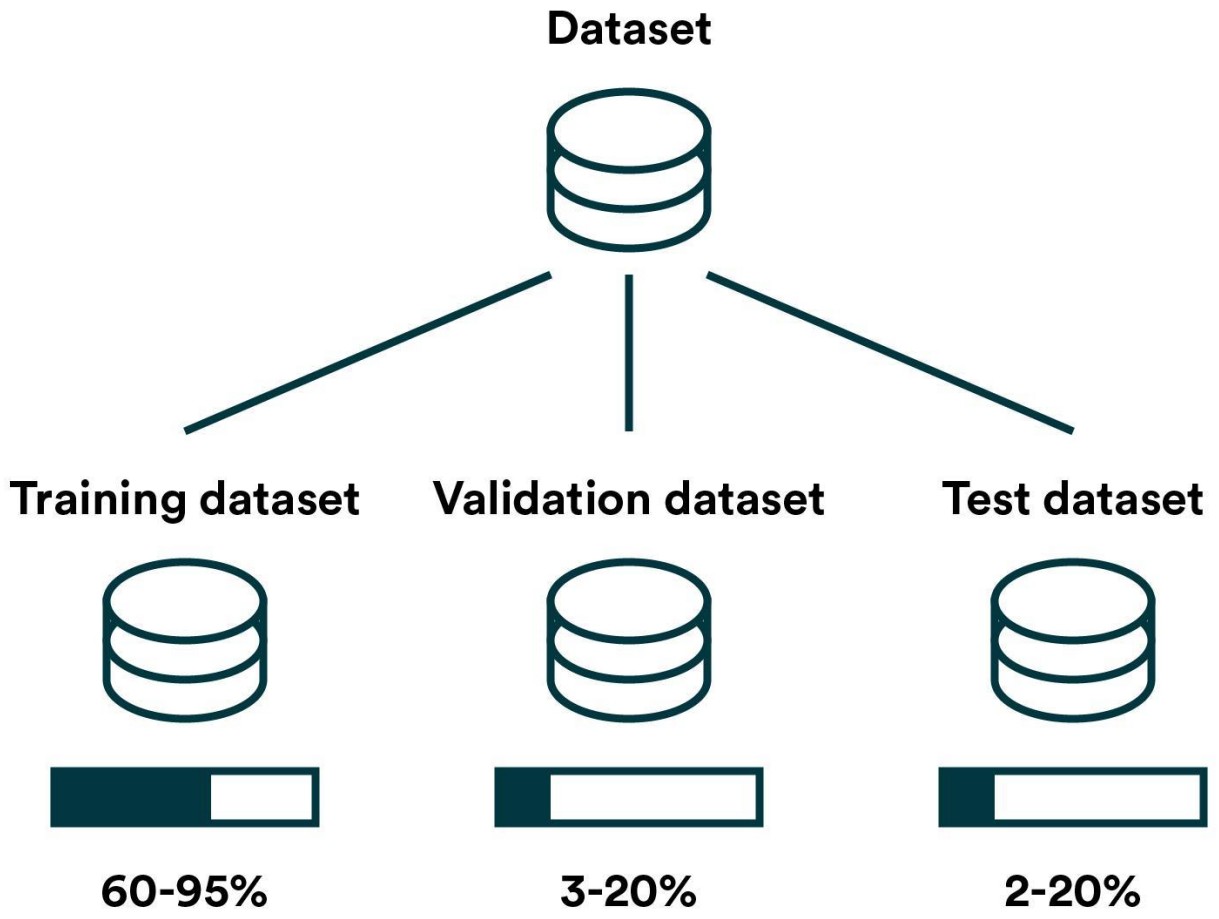
Entendendo Conceitos Principais

- **Treinamento e inferência**: Etapa em que o algoritmo aprende padrões a partir dos dados disponíveis.
  - A inferência ocorre quando o modelo já treinado recebe uma nova amostra e produz uma previsão, como identificar a espécie de um animal em uma imagem.



Entendendo Conceitos Principais

- **Treino, Validação e Teste**: Conjuntos utilizados em diferentes etapas do desenvolvimento do modelo.
  - **Treino** é utilizado para ajustar o modelo;
  - **Validação** compara alternativas e ajustar parâmetros;
  - **Teste** avalia o desempenho final em dados não utilizados nas etapas anteriores.



Entendendo Conceitos Principais

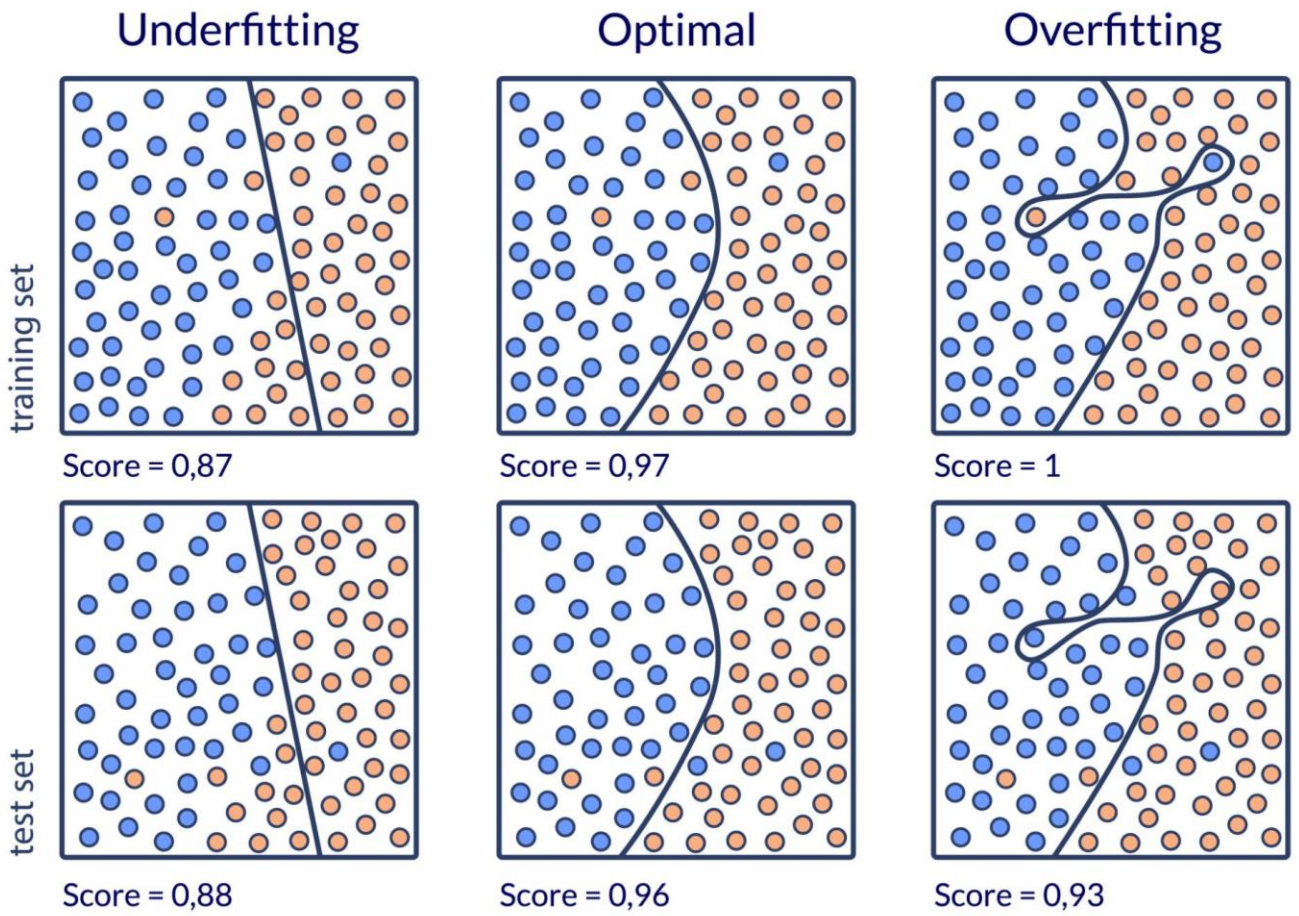
- **Generalização**: capacidade de um modelo de reconhecer padrões corretamente em dados novos, diferentes daqueles utilizados no treinamento.
- **Overfitting (ou sobreajuste)**: acontece quando o modelo aprende excessivamente os detalhes dos dados de treinamento, inclusive ruídos e particularidades, apresentando bom desempenho nesses dados, mas resultados inferiores em novas amostras.

Entendendo Conceitos Principais

Underfitting: o modelo não aprende adequadamente os padrões.

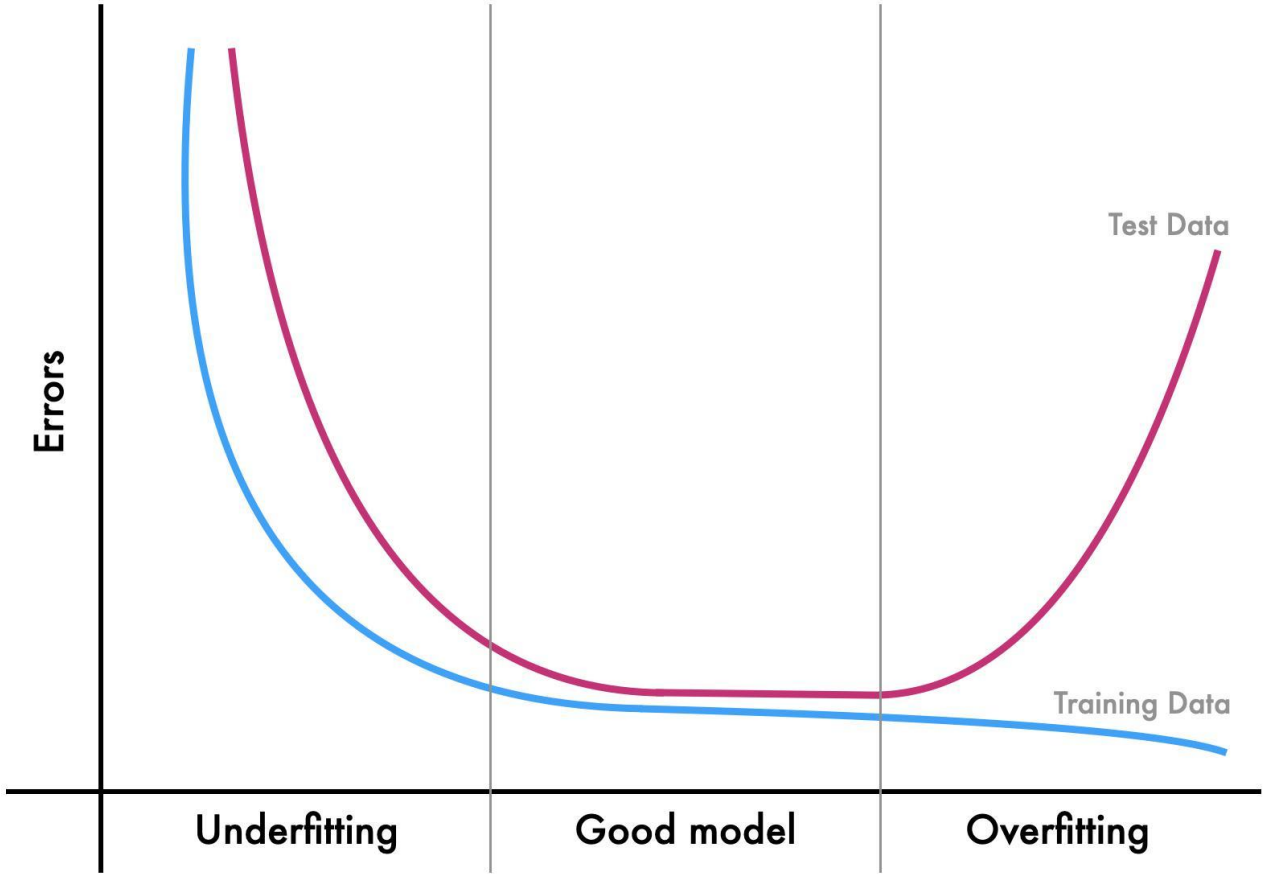
Optimal: aprende padrões relevantes e funciona bem em dados novos.

Overfitting: ajusta-se excessivamente aos dados de treinamento e tem dificuldade com exemplos inéditos



Entendendo Conceitos Principais

Análise gráfica do desempenho do modelo .



Métricas de Desempenho

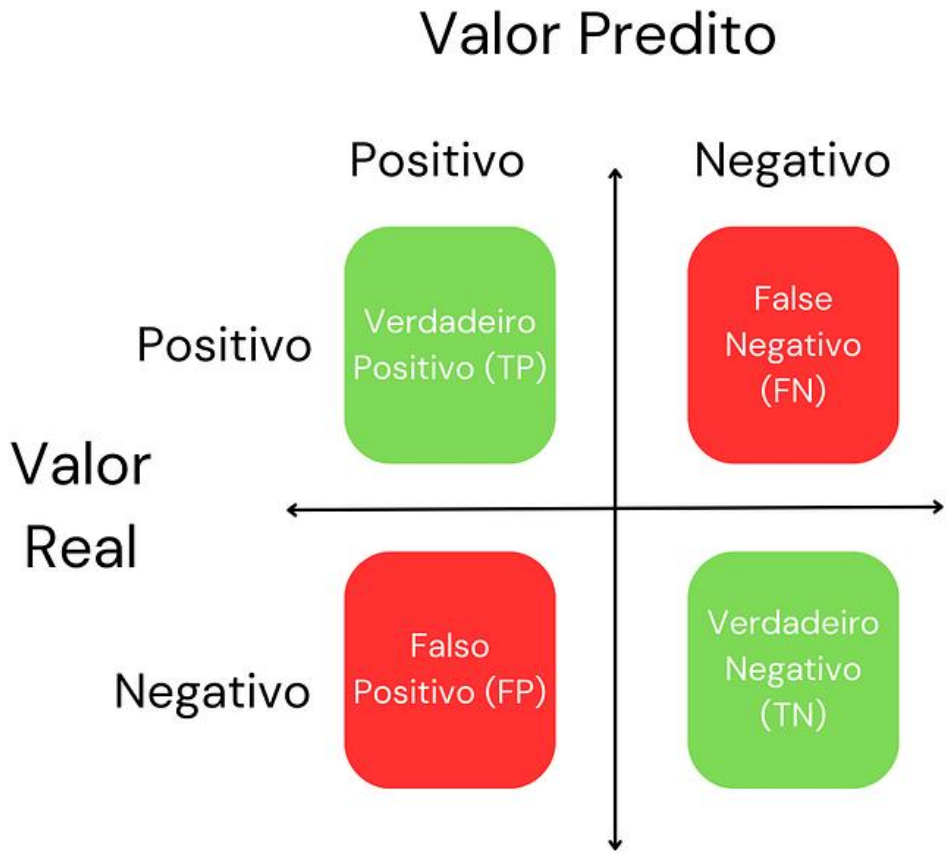
Acurácia: Percentual de imagens de cada classe, classificadas corretamente pelo modelo em relação ao total de imagens avaliadas.

Falso Positivo: Quando o modelo classifica uma imagem como pertencente a uma classe, mas ela, na realidade, pertence a outra.

Falso Negativo: Quando o modelo não identifica uma imagem como pertencente à classe à qual ela realmente pertence.

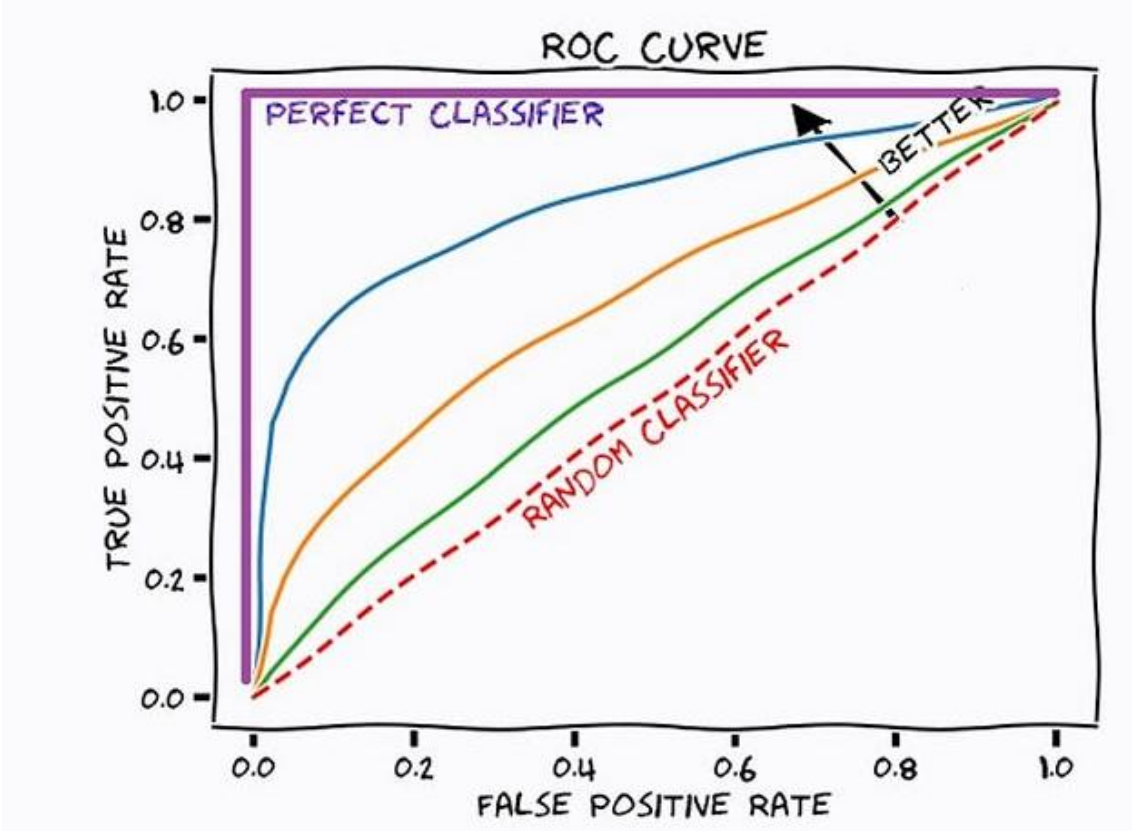
Métricas de Desempenho

Matriz de confusão: Tabela que compara as classes reais das imagens com as classes previstas pelo modelo, permitindo visualizar os acertos e os erros de classificação. limiares de decisão.



Métricas de Desempenho

Curva ROC (Receiver Operating Characteristic): Gráfico que avalia a capacidade do modelo de distinguir entre classes, relacionando a taxa de verdadeiros positivos com a taxa de falsos positivos para diferentes limiares de decisão.

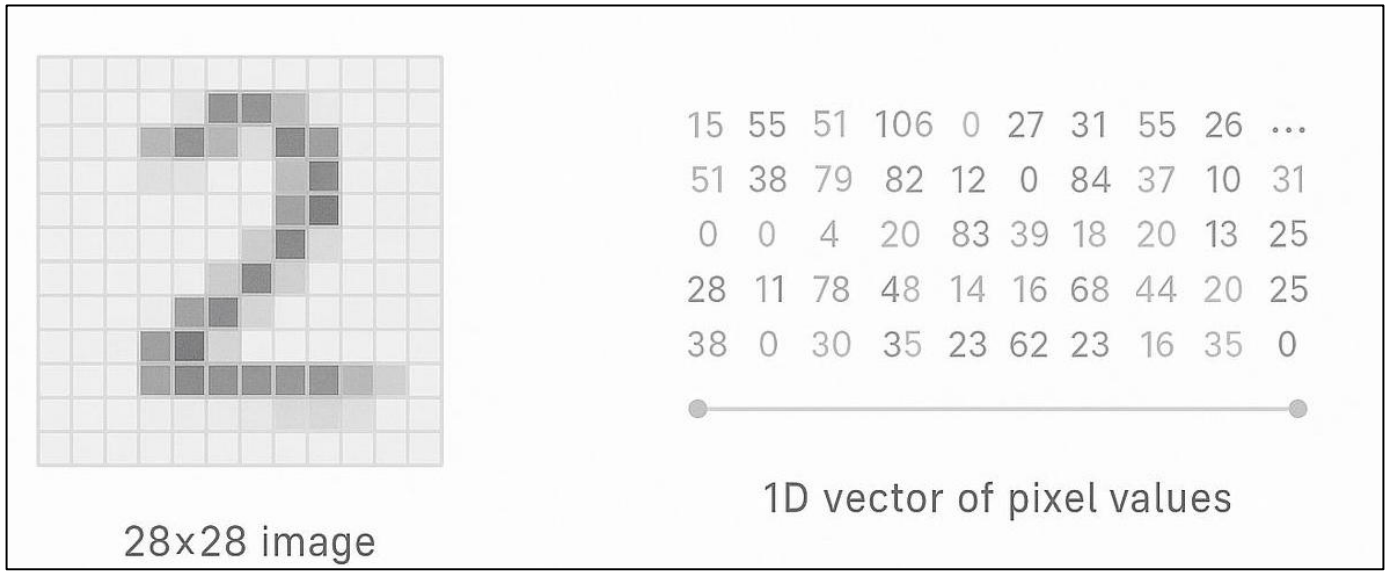


Métricas de Desempenho

- **Precisão**: indica, entre as imagens que o modelo classificou como pertencentes a uma determinada classe, quantas realmente pertencem a ela. **Quanto maior, menor a quantidade de falsos positivos.**
- **Recall**: indica, entre todas as imagens que realmente pertencem a uma classe, quantas foram identificadas corretamente pelo modelo. **Quanto maior, menor a quantidade de falsos negativos.**
- **F1-score**: é a média harmônica entre precision e recall, combinando as duas métricas em um único indicador. **Quanto mais próximo de 1, melhor o equilíbrio entre elas.**
- **Support**: representa a quantidade de imagens de cada classe presentes no conjunto de teste. Esse valor indica quantas amostras reais foram utilizadas para avaliar o desempenho do modelo.

Como transformar uma imagem em dados?

O Algoritmo tradicional não recebe necessariamente uma imagem como um objeto visual. Ele recebe uma representação numérica..



$$28 \times 28 = 784$$

Como transformar uma imagem em dados?

- Analisar imagem pixel a pixel pode produzir um vetor de características muito grande.
- Duas possibilidades:
  - Utilizar diretamente os valores dos pixels;
  - Extrair características com técnicas clássicas de visão computacional.

Como transformar uma imagem em dados?

Característica	Aplicação
Histograma de cores	Classificação de frutas
Área e perímetro	Reconhecimento de formas
Aspect ratio	Diferenciar objetos
HOG	Características de formas e bordas
Intensidade dos pixels	Dígitos e imagens simples

Aplicações

Aplicações de KNN e SVM com HOG